

گزارش پروژه

مدل سازی آماری و تحلیل رویدادهای نادر با روش های پیشرفته مونت کارلو

نام و نام خانوادگی: علی تقی زاده

شماره دانشجویی: ۴۰۳۱۳۰۰۸

مخزن کد پروژه

github.com/alitkbbl/Water-Quality-Rare-Events

تحلیل کیفیت آب، برازش آماری، شبیه سازی مونت کارلو و نمونه گیری اهمیتی

۳۰ خرداد ۱۴۰۵

۱ مقدمه

در تحلیل سیستم های حساس، مانند بررسی کیفیت آب، تنها دانستن وضعیت میانگین یا رفتار معمول سیستم کافی نیست. در بسیاری از کاربردهای واقعی، آنچه اهمیت بیشتری دارد، پیش بینی احتمال وقوع شرایط بحرانی است؛ برای نمونه، حالتی که غلظت یک ماده شیمیایی از حد مجاز فراتر می رود. چنین رخدادهایی ممکن است به ندرت اتفاق بیفتند، اما اثر آن ها می تواند بسیار مهم و حتی خطرناک باشد.

در این پروژه، تمرکز اصلی بر تحلیل غلظت کلرامین (Chloramines) قرار دارد. روند کار از شناخت اولیه داده ها و استخراج یک مدل آماری مناسب آغاز شد. سپس برای شبیه سازی داده ها، روش پایه رد-پذیرش پیاده سازی شد. در ادامه، مسئله اصلی پروژه یعنی محاسبه احتمال یک رویداد نادر بررسی شد و نشان داده شد که روش مونت کارلو استاندارد (Standard Monte Carlo) در چنین شرایطی کارایی مناسبی ندارد. در نهایت، با استفاده از روش نمونه گیری اهمیت (Importance Sampling)، کاهش چشمگیری در هزینه محاسباتی و خطای تخمین به دست آمد.

۲ شناخت داده ها و استخراج مدل آماری پایه

اولین گام در هر پروژه شبیه سازی، شناخت رفتار واقعی داده ها است. در این پروژه، کار با مجموعه داده ای شامل 3276 مشاهده معتبر از غلظت کلرامین آغاز شد. تحلیل های اولیه نشان داد که میانگین غلظت برابر با 7.122 و واریانس آن برابر با 2.505 است.

برای شبیه سازی این متغیر در محیط کامپیوتر، لازم بود یک مدل ریاضی مناسب برای تابع چگالی احتمال، یا همان PDF، انتخاب شود. از آنجا که غلظت یک ماده شیمیایی نمی تواند مقدار منفی داشته باشد، دو توزیع گاما و وایبول به عنوان گزینه های اصلی در نظر گرفته شدند. سپس با استفاده از روش برآورد بیشینه درست نمایی (MLE)، پارامترهای بهینه هر توزیع محاسبه شد:


جدول ۱: پارامترهای برآورد شده برای توزیع های کاندید

توزیع	پارامتر اول	پارامتر دوم
گاما	شکل: $k = 18.0283$	مقیاس: $\theta = 0.3951$
وایبول	شکل: $c = 4.8842$	مقیاس: $\lambda = 7.7437$

• توزیع گاما: پارامتر شکل $k = 18.0283$ و پارامتر مقیاس $\theta = 0.3951$

• توزیع وایبول: پارامتر شکل $c = 4.8842$ و پارامتر مقیاس $\lambda = 7.7437$

پرسش اصلی این بود که کدام یک از این دو مدل، رفتار واقعی داده ها را بهتر نمایش می دهد.



شکل ۱: برازش توزیع ها روی هیستوگرام داده های کلرامین

۱.۲ تحلیل نمودار و انتخاب مدل نهایی

همان طور که در شکل ۱ مشاهده می شود، توزیع وایبول، که با خط چین سبز نمایش داده شده است، در تخمین نقطه اوج داده ها دقت کافی ندارد و قله توزیع را کمتر از مقدار واقعی نشان می دهد. در مقابل، توزیع گاما، که با خط قرمز پیوسته مشخص شده است، هم در بخش مرکزی داده ها و هم در نواحی ابتدایی و انتهایی نمودار، انطباق بهتری با هیستوگرام تجربی دارد.

بنابراین، توزیع گاما به عنوان مدل آماری اصلی و تابع هدف پروژه انتخاب شد. از این مرحله به بعد، این تابع با نماد $f(x)$ نمایش داده می شود و مبنای شبیه سازی ها و تحلیل های بعدی خواهد بود.

بنابراین تابع هدف نهایی به صورت زیر است:

$$f(x) = \frac{1}{\Gamma(k)\theta^k} x^{k-1} e^{-x/\theta}, \quad k = 18.0283, \theta = 0.3951. \quad (۱)$$

۳ پیاده سازی نمونه گیری با الگوریتم رد-پذیرش

پس از انتخاب تابع هدف $f(x)$ ، مسئله بعدی این بود که چگونه می توان اعداد تصادفی ای تولید کرد که از همین توزیع گاما پیروی کنند. برای درک بهتر سازوکار نمونه گیری، به جای استفاده از توابع آماده، الگوریتم رد-پذیرش (Accept-Reject) از ابتدا پیاده سازی شد.

ایده اصلی این روش آن است که از یک توزیع ساده تر به عنوان توزیع پیشنهادی استفاده شود. در این پروژه، توزیع یکنواخت روی بازه $[0, 16]$ انتخاب شد. بنابراین تابع چگالی پیشنهادی برابر است با:


$$g(x) = 0.0625$$

چالش اصلی در این روش، یافتن ضریب M است؛ به گونه ای که برای تمام مقادیر x داشته باشیم:

$$M \cdot g(x) \geq f(x)$$

با محاسبه نقطه بیشینه توزیع گاما مشخص شد که مقدار بیشینه در $x = 6.7279$ رخ می دهد و مقدار تابع در این نقطه برابر با 0.2435 است. در نتیجه، ضریب M به صورت زیر به دست آمد:

$$M = 3.8959$$



شکل ۲: نتایج نمونه گیری با الگوریتم رد-پذیرش

۱.۳ تحلیل عملکرد الگوریتم

الگوریتم برای تولید 10000 نمونه معتبر اجرا شد. در عمل، برنامه مجبور شد 39709 نمونه کاندید تولید کند تا در نهایت تعداد نمونه های پذیرفته شده به مقدار مورد نظر برسد. نرخ پذیرش تجربی برابر با 0.2518، یعنی حدود 25 درصد، به دست آمد.

این نتیجه با مقدار تئوری نیز سازگار است. از نظر نظری، نرخ پذیرش مورد انتظار برابر است با:

$$\frac{1}{M} = 0.2567$$

نزدیکی مقدار تجربی 0.2518 به مقدار تئوری 0.2567 نشان می دهد که پیاده سازی الگوریتم به درستی انجام شده است. همچنین، همان طور که در شکل ۲ دیده می شود، هیستوگرام نمونه های پذیرفته شده به خوبی با منحنی توزیع هدف منطبق است. این موضوع تأیید می کند که نمونه های تولید شده واقعاً از توزیع گامای مورد نظر پیروی می کنند.

۴ شبیه سازی مونت کارلو استاندارد و چالش رویدادهای نادر


هدف نهایی پروژه، محاسبه احتمال وقوع یک وضعیت بحرانی بود؛ یعنی احتمال اینکه غلظت کلرامین از آستانه مشخص $\tau = 12.0$ فراتر رود. مقدار واقعی و تحلیلی این احتمال برابر است با:

$$\gamma = 0.00621$$

این مقدار تقریباً معادل 0.62% است. به بیان ساده تر، چنین رخدادی به طور میانگین در حدود 6 بار از هر 1000 نمونه اتفاق می افتد. بنابراین با یک رویداد نادر روبه رو هستیم.

در ابتدا، روش مونت کارلو استاندارد (SMC) برای تخمین این احتمال به کار گرفته شد. نتایج اولیه نشان دادند که این روش در حجم نمونه های پایین، دقت مناسبی ندارد:

- برای حجم نمونه $N = 1000$ ، مقدار احتمال برابر با 0.002 تخمین زده شد. خطای نسبی یا CV در این حالت برابر با 0.7064 بود؛ یعنی حدود 70 درصد خطا.
- برای رساندن خطا به کمتر از یک درصد، یعنی $CV < 0.01$ ، لازم بود حجم نمونه تا $N = 10000000$ افزایش یابد. در این حالت مقدار CV به حدود 0.004 رسید.



شکل ۳: همگرایی روش مونت کارلو استاندارد و رفتار خطای نسبی در مقیاس لگاریتمی

۱.۴ تحلیل محدودیت های روش مونت کارلو استاندارد

شکل ۳ نشان می دهد که خطای روش مونت کارلو استاندارد با نرخ تئوری زیر کاهش می یابد:

$$\frac{1}{\sqrt{N}}$$

این نرخ کاهش خطا، به خصوص در مسئله رویدادهای نادر، بسیار کند است. دلیل آن نیز روشن است: در روش استاندارد، بیشتر نمونه ها در ناحیه معمولی توزیع تولید می شوند؛ یعنی حوالی میانگین که در این مسئله نزدیک به مقدار 7 است. اما رویداد مورد نظر ما در ناحیه بحرانی، یعنی مقادیر بزرگتر از 12، رخ می دهد.

در نتیجه، بخش بزرگی از زمان محاسباتی صرف تولید نمونه هایی می شود که هیچ نقشی در تخمین احتمال رویداد نادر ندارند. این مسئله باعث می شود روش مونت کارلو استاندارد برای چنین کاربردهایی بسیار پرهزینه و ناکارآمد باشد.

از نظر آماری، چون $\mathbb{I}_{\{X_i > \tau\}}$ یک متغیر برنولی با احتمال موفقیت γ است، واریانس برآوردگر مونت کارلو استاندارد به صورت زیر به دست می آید:

$$\text{Var}(\hat{\gamma}_{\text{SMC}}) = \frac{\gamma(1-\gamma)}{N}, \quad \text{CV} = \frac{\sqrt{\text{Var}(\hat{\gamma}_{\text{SMC}})}}{\gamma} \approx \sqrt{\frac{1-\gamma}{\gamma N}}. \quad (2)$$

برای یک رویداد نادر، مقدار γ بسیار کوچک است. در این پروژه داریم $\gamma \approx 6.21 \times 10^{-3}$ ؛ بنابراین خطای نسبی تقریباً به عبارت زیر وابسته می شود:

$$\text{CV} \approx \frac{1}{\sqrt{\gamma N}}. \quad (3)$$

رابطه (۳) نشان می دهد که با کوچک شدن γ ، خطای نسبی به سرعت افزایش می یابد. به همین دلیل، برای $N = 1000$ مقدار CV حدود 0.71 است و تخمین 0.002 در برابر مقدار واقعی 0.00621 دقت مناسبی ندارد. تنها زمانی به دقت قابل قبول می رسیم که حجم نمونه تا حدود 10^6 یا 10^7 افزایش یابد. این پدیده همان مشکل واریانس بالا در شبیه سازی رویدادهای نادر است؛ یعنی برای رسیدن به یک سطح خطای ثابت، تعداد نمونه ها باید تقریباً متناسب با $\frac{1}{\gamma}$ رشد کند.

۵ رویکرد هوشمند با نمونه گیری اهمیت

برای عبور از محدودیت روش مونت کارلو استاندارد، از تکنیک نمونه گیری اهمیت (Importance Sampling) استفاده شد. ایده اصلی این روش آن است که به جای نمونه گیری کورکورانه از توزیع اصلی، نمونه ها از توزیعی تولید شوند که تمرکز بیشتری بر ناحیه مهم مسئله دارد.


در این پروژه، ناحیه مهم همان ناحیه بحرانی است؛ یعنی مقادیر بزرگتر از آستانه $\tau = 12.0$. بنابراین یک توزیع پیشنهادی جدید با نماد $q(x)$ تعریف شد که جرم احتمالی بیشتری را در این ناحیه قرار می دهد.

برای متمرکز کردن نمونه ها در ناحیه بحرانی $x > \tau$ ، توزیع پیشنهادی $q(x)$ به صورت یک توزیع گاما انتخاب شد؛ با این تفاوت که میانگین آن به سمت آستانه بحرانی جابه جا شده است. این انتخاب باعث می شود قله توزیع پیشنهادی نزدیک $\tau = 12$ قرار گیرد و در نتیجه، نمونه های بیشتری از ناحیه مؤثر در محاسبه احتمال رویداد نادر تولید شوند.

برآوردگر نمونه گیری اهمیتی (Importance Sampling) و وزن اهمیت به صورت زیر تعریف می شوند:

$$\hat{\gamma}_{\text{IS}} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{\{X_i > \tau\}} w(X_i), \quad w(x) = \frac{f(x)}{q(x)}. \quad (4)$$

در رابطه (۴)، تابع $f(x)$ چگالی هدف، یعنی همان توزیع گامای برازش شده روی داده های کلرامین، و تابع $q(x)$ چگالی پیشنهادی است. وزن $w(x)$ نیز نقش جبرانی دارد و باعث می شود با وجود نمونه گیری از $q(x)$ ، تخمین نهایی همچنان نسبت به توزیع اصلی $f(x)$ معتبر باقی بماند.



شکل ۴: استراتژی نمونه گیری اهمیت با تمرکز روی ناحیه بحرانی

۱.۵ استراتژی و نتایج

همان طور که در شکل ۴ مشخص است، توزیع پیشنهادی $q(x)$ به گونه ای انتخاب شده که قله آن نزدیک به ناحیه وقوع رویداد نادر قرار گیرد. به این ترتیب، نمونه های بیشتری در حوالی مقادیر بزرگ تر از ۱۲ تولید می شوند. البته برای اینکه تخمین همچنان بدون اریبی باقی بماند، از وزن های جبرانی یا نسبت درست نمایی (Likelihood Ratio) استفاده شد.

نتایج به دست آمده بسیار قابل توجه بودند. روش نمونه گیری اهمیت تنها با $N = 1000$ نمونه توانست احتمال را برابر با ۰.۰۰۶۱۲ تخمین بزند و خطای نسبی را به مقدار ۰.۰۳۸۷ برساند. این مقدار کمتر از ۴ درصد است و برای چنین حجم نمونه ای بسیار مناسب محسوب می شود.

جدول ۲: مقایسه عددی عملکرد روش مونت کارلو استاندارد و نمونه گیری اهمیت

روش	حجم نمونه	تخمین احتمال	خطای نسبی
SMC	1000	0.00200	0.7064
SMC	100000	0.00621	0.0400
IS	1000	0.00612	0.0387
IS	100000	نزدیک به مقدار تحلیلی	0.0040

جدول ۲ نشان می دهد که روش نمونه گیری اهمیت با تنها ۱۰۰۰ نمونه، به دقتی تقریباً مشابه روش مونت کارلو استاندارد با ۱۰۰۰۰۰ نمونه می رسد. بنابراین، در این مسئله کاهش هزینه محاسباتی تقریباً صدبرابری حاصل شده است.


این مقایسه نشان می دهد که روش نمونه گیری اهمیت توانسته است با تعداد نمونه ای ۱۰۰ برابر کمتر، به دقتی تقریباً مشابه و حتی کمی بهتر برسد. همچنین در حجم نمونه ۱۰۰۰۰۰، خطای روش IS به مقدار بسیار کوچک

0.0040 رسید؛ در حالی که روش SMC برای رسیدن به چنین سطحی از دقت، به حدود 10000000 نمونه نیاز داشت.

۶ جمع بندی نهایی و مقایسه کارایی محاسباتی

پس از پیاده سازی و تحلیل جداگانه دو روش مونت کارلو استاندارد و نمونه گیری اهمیت، مرحله نهایی مقایسه مستقیم کارایی آنهاست. در مسائل مهندسی و علوم محاسباتی، یک روش خوب فقط نباید به پاسخ درست برسد؛ بلکه باید این کار را با هزینه محاسباتی قابل قبول انجام دهد.

در این پروژه، هزینه محاسباتی با تعداد نمونه های مورد نیاز، یعنی N ، سنجیده می شود. همچنین کارایی روش ها بر اساس سرعت کاهش خطای نسبی یا CV ارزیابی شده است.



شکل ۵: مقایسه کارایی روش مونت کارلو استاندارد و نمونه گیری اهمیت

۱.۶ تحلیل نهایی

شکل ۵ خلاصه اصلی نتایج پروژه را به خوبی نشان می دهد. در این نمودار، خطای نسبی هر دو روش در برابر حجم نمونه، در مقیاس لگاریتمی-لگاریتمی رسم شده است. فاصله زیاد بین دو منحنی نشان می دهد که نمونه گیری اهمیت از نظر محاسباتی بسیار کارتر از روش مونت کارلو استاندارد است. چند نکته اصلی از این نمودار قابل برداشت است:

۱. شروع متفاوت دو روش: روش SMC در حجم نمونه پایین با خطای بسیار بزرگی آغاز می شود. برای مثال، در $N = 1000$ ، خطای نسبی آن حدود 70 درصد است. در مقابل، روش IS با همین تعداد نمونه، خطایی کمتر از 4 درصد دارد.
۲. کاهش خطا با افزایش حجم نمونه: در هر دو روش، با افزایش N ، خطا کاهش می یابد. با این حال، منحنی مربوط به IS تقریباً در تمام نقاط، چندین مرتبه پایین تر از منحنی SMC قرار دارد.

۳. معنای عملی اختلاف دو روش: برای رسیدن به خطای نسبی حدود 4 درصد، یعنی $CV = 0.04$ ، روش SMC به $N = 100000$ نمونه نیاز دارد. در حالی که روش IS همین دقت را با $N = 1000$ نمونه به دست می آورد.

بنابراین، با یک تغییر هوشمندانه در استراتژی نمونه گیری و تمرکز دادن نمونه ها روی ناحیه بحرانی، توانستیم همان سطح دقت را با کاهش صدبرابری هزینه محاسباتی به دست آوریم.

۷ نتیجه گیری

این پروژه نشان داد که در تحلیل مسائل واقعی، به ویژه در حوزه هایی مانند تحلیل ریسک، قابلیت اطمینان و پایش کیفیت، رویدادهای نادر نقش بسیار مهمی دارند. اگرچه روش مونت کارلو استاندارد از نظر مفهومی ساده و قابل فهم است، اما در مواجهه با رویدادهای نادر می تواند بسیار کند و پرهزینه باشد.

در مقابل، نمونه گیری اهمیت (Importance Sampling) نشان داد که با انتخاب مناسب توزیع پیشنهادی و استفاده از وزن های جبرانی، می توان دقت تخمین را به شکل قابل توجهی افزایش داد. این روش صرفاً یک بهینه سازی کوچک نیست، بلکه در چنین مسئله هایی ابزاری ضروری برای تبدیل یک محاسبه سنگین و زمان بر به یک تحلیل سریع، دقیق و قابل اعتماد است.